

Vérification finale — le brief, point par point, contre la preuve

Première version le 23/09/2026 ; **mise à jour le 24/09/2026 après v2.7.0**. Chaque ligne a été **vérifiée** par une commande, pas de mémoire. Dépôt `Ganda15/mardik-api-mlops_v2`, `main` = `cac6202`, version en service `v2.7.0`.

Sommaire

1. Les 10 tests d'acceptance fournis	2
2. Au-delà des tests : prouvé en vrai	2
3. Les 5 livrables	3
4. Les questions de réflexion du brief	3
5. Ce qui n'est pas fait — dit tel quel	4

1. Les 10 tests d'acceptance fournis

Commande : `pytest tests/acceptance -v`.

#	Test du brief	Test fourni	Résultat
1	document long → /v2 selon le contrat, avec score	<code>test_contrat_v2_long_analyse_sans_troncature</code>	✓ PASSED
2	requête invalide → erreur explicite	<code>test_erreurs_explicites_jamais_de_500</code>	✓ PASSED
3	client v1 inchangé pendant le canary	<code>test_client_v1_fonctionne</code>	✓ PASSED
4	fusion → version étiquetée, version identifiable	<code>test_etiquetage_version_apres_gate</code>	✓ PASSED
5	gate en échec → livraison bloquée	<code>test_gate_evaluation_note_par_version</code>	✓ PASSED
6	dérive → rollback via la chaîne, tracé	<code>test_rollback_en_une_operation</code>	✓ PASSED
7	métriques conformes → promotion ; sinon non	<code>test_promotion_canary_puis_totale</code>	✓ PASSED
8	cas à faible confiance → jeu d'éval → rejoué	<code>test_evaluation_enrichie_latence_et_cout</code>	✓ PASSED
9	tableau de bord : 5 signaux visibles	<code>test_dashboard_par_version</code>	✓ PASSED
10	journal : tout ajustement avec son signal	<code>test_journal_derive_alerte_jamais_de_rollback_au_tomatique</code>	✓ PASSED

Suite complète : **236 passed** · couverture **84 %** (seuil 80 % appliqué par la chaîne) · `ruff` : aucune erreur · test des données : 12 contrats + 1 cas de production valides.

2. Au-delà des tests : prouvé en vrai

Exigence	Preuve réelle	Fichier
Fusion → version étiquetée, publiée par la chaîne	15 PR fusionnées, 13 versions <code>v2.0.0</code> → <code>v2.7.0</code> , dernier run <code>main</code> 7/7 ; rappel 1,000, précision 0,95 – 0,99 sur 17 passages du gate réel	GitHub Actions
Gate en échec → bloqué	<code>gate-reel</code> : 14 passés, 3 refusés sur la latence (P95 12,5 s ; 8,7 s ; 12,8 s), sans tag ; la publication de la fusion de PR #12 a été refusée faute de tag, puis a abouti avec PR #13	<code>preuves/...gate-reel-ECHEC-latence...txt</code>
Vrai modèle identifié dans la version	manifeste <code>v2.4.0</code> : <code>gpt-5.4</code> , signature 0,9914 / 0,0 / 12	<code>preuves/...manifeste...v2.4.0.json</code>
Rollback sur signal, décision humaine	alerte médiane 0,542 → refus de promotion → clic nommé → <code>v1.0.0</code>	<code>preuves/...derive-reelle-*</code>
Promotion pilotée	5 requêtes saines → <code>promotion</code> palier 100	<code>preuves/...promotion-live...txt</code>
Enrichissement	cas réel capturé à 0,53, masqué, étiqueté, rejoué par la chaîne	<code>preuves/...enrichissement-live...txt</code>
Latence < 8 s	c12 : 2,75 – 4,20 s (8 requêtes) ; gate réel P95 4,4 – 7,6 s sur les passages réussis	<code>preuves/...latence-ou-passent...txt</code>

Exigence	Preuve réelle	Fichier
Coût < 0,15 €	0,033 € moyen, 0,088 pire cas, tarifs catalogue entrée/sortie	preuves/...cout-reel...txt
Frontend par un lien	tunnel : page 200, POST sans code 401	vérifié le 23/09 au soir
v1 intacte	/v1 : 200, exactement clauses, modele, tronque, version	vérifié le 23/09 au soir
Protection de main	checks lint, tests, gate-evaluation, à jour exigé, admins inclus	API GitHub
Collection de démo	Bruno : 10/10 requêtes, 10/10 assertions	preuves/...bruno...txt
Score de confiance calibré (v2.6.0, v2.7.0)	Platt appris sur 431 clauses réelles (13 contrats + 37 variantes sans un article) ; ECE par contrat 0,026 → 0,0004 ; plafond 0,993	eval/calibration_donnees.jsonl, eval/calibration_ablation.jsonl, models/v2/config.yaml
Plafond de taille (v2.5.0)	au-delà de 200 000 caractères : 413 avant tout appel au modèle ; seules les clauses à extrait prouvé sont renvoyées	app/api_v2.py, tests/test_clauses_sans_preuve.py

3. Les 5 livrables

Livable	Où	État
Dossier de conception	livrables/Mardik-Conception-Chantier1.pdf, ... Chantier2.pdf, 4 schémas .drawio + .png	✓ envoyé le 18/09, validé
API v2, v1 intacte	app/api_v2.py, app/api_v1.py (fourni, non modifié)	✓
Chaîne LLMOps (yaml)	.github/workflows/llmops.yaml, gate-reel.yaml, rollback.yaml	✓
Observabilité : tableau de bord + 3 boucles + journal	ops/dashboard.py, ops/watcher.py, app/pilotage.py, ops/registry/journal.jsonl	✓
Client frontend par un lien	app/static/index.html, scripts/demo.py public	✓ (lien éphémère)

4. Les questions de réflexion du brief

Toutes les questions — celles du formateur (6 + 6) et celles des apprenants — ont une réponse écrite, une ligne chacune, avec sa section : **annexe A** de Mardik-Conception-Chantier1.md (23 questions) et de Mardik-Conception-Chantier2.md (13 questions).

Ce qui a changé entre la conception (18/09) et le code, et où c'est tracé — la conception disait vrai à sa date ; le développement a corrigé ces points, chacun avec sa raison :

Réponse du 18/09	Construit	Tracé dans
« aucune découpe : un appel unique, plafond 413 »	map-reduce par sections (imposé par un test fourni) ; le 413 est construit en v2.5.0	docs/spec-v2-perimetre.md §6, app/api_v2.py
route /v2/analyses, score « calibré »	/v2/analyse (dépôt) ; score calibré ajouté le 24/09 (confiance_calibree, v2.6.0 et v2.7.0)	models/v2/config.yaml (calibration)
routeur lisant weights.json	index du registre (canary_percent)	docs/spec-ch2-pilotage.md §6

5. Ce qui n'est pas fait — dit tel quel

- Le tarif Azure de la ressource n'est pas confirmé sur le portail : 0,033 € est un coût **au catalogue**.
- La queue de latence du fournisseur dépasse parfois 8 s : **3 passages sur 17** — le gate les a refusés. Rappel et coût inchangés ; la cause est le temps de réponse d'Azure, pas le code.
- Le score calibré repose sur 431 clauses, dont **13 fausses — toutes « garantie »** : c'est le seul type sur lequel le modèle se trompe ; une définition plus précise de « garantie » dans le prompt reste à faire. Aucune réponse n'est tombée entre 0,77 et 0,95 de score brut : le modèle est soit sûr et juste, soit hésitant et faux.
- L'adresse du lien public change à chaque redémarrage du tunnel.

Levé depuis le 23/09 : le score non calibré (calibration v2.6.0 puis v2.7.0) ; l'absence de plafond de taille et les clauses non vérifiées renvoyées (v2.5.0) ; la publication bloquée de PR #12 (publiée avec PR #13).